INFORME DE CLUSTERING NO SUPERVISADO
APLICACIÓN DE K-MEANS AL DATASET WINE

EDIXON HARBEY RUBIANO ROBAYO

ANALITICA Y CIENCIA DE DATOS
UNIVERSIDAD DE CUNDINAMARCA
MACHINE LEARNING
LIC. MONICA MARIA FONSECA
NOVIEMBRE 2026

Resumen

El presente informe documenta el desarrollo y evaluación de un modelo de agrupamiento no supervisado mediante el algoritmo K-Means aplicado al conjunto de datos fisicoquímicos de vinos (Wine Dataset). El objetivo principal del estudio consistió en identificar la estructura de agrupamiento natural de las muestras basándose exclusivamente en sus 13 variables predictoras cuantitativas, excluyendo la variable de etiqueta en la fase de entrenamiento. Tras aplicar la estandarización de datos mediante StandardScaler, se evaluaron configuraciones del algoritmo desde K = 2 hasta K = 6. La evaluación combinada del Método del Codo y el índice Silhouette indicó que K = 3 representa la partición óptima del espacio de datos, logrando un Silhouette Score de 0.2849, un índice Davies-Bouldin de 1.3892 y un puntaje Calinski-Harabasz de 70.94. La reducción de dimensionalidad con PCA (explicando el 55.41% de la varianza con dos componentes) confirmó la formación de tres clusters claramente diferenciados. Las diferencias entre los grupos están guiadas principalmente por la concentración de prolina, flavonoides, fenoles totales y la intensidad de color, ofreciendo una segmentación robusta alineada con el origen químico de las muestras.

Descripción del Dataset y Preprocesamiento

El conjunto de datos utilizado corresponde al estándar Wine Data Set del repositorio UCI Machine Learning. Contiene análisis fisicoquímicos de vinos producidos en una misma región de Italia pero derivados de tres cultivares diferentes.

- **Número de Registros:** 178 observaciones independientes (muestras de vino).
- **Número de Variables:** 14 variables en total (1 variable objetivo/clase y 13 variables predictoras cuantitativas de tipo continuo).
- **Variables Predictoras (X):** Alcohol, Ácido málico, Ceniza, Alcalinidad de la ceniza, Magnesio, Fenoles totales, Flavonoides, Fenoles no flavonoides, Proantocianidinas, Intensidad de color, Matiz, OD280/OD315 de vinos diluidos y Prolina.
- **Calidad de Datos:** La revisión inicial confirmó la ausencia de valores nulos o faltantes (0 nulos en todas las columnas).
- **Estandarización de Datos:** Se identificaron magnitudes drásticamente dispares entre variables (por ejemplo, Prolina con valores hasta 1680 frente a Fenoles no flavonoides entre 0.13 y 0.66). Por ello, fue imprescindible aplicar StandardScaler para transformar las variables a media 0 y varianza unitaria (z-score), evitando que las características de gran escala dominen los cálculos de distancia euclidiana.

Característica	Detalle en el Dataset
Tamaño de la Muestra	178 filas x 14 columnas
Variables Predictoras	13 características fisicoquímicas continuas
Variable Objetivo (Target)	Clase del vino (1, 2 o 3) — Descartada para el modelado
Transformación Aplicada	StandardScaler (Media = 0, Desviación Estándar = 1)

Metodología de Clustering

Para el proceso de particionamiento de datos se seleccionó el algoritmo K-Means debido a su eficiencia computacional y efectividad en espacios continuos de media a alta dimensión.

Algoritmo e Hiperparámetros

- **Algoritmo:** K-Means (Partitioning Clustering).
- **Métrica de Distancia:** Distancia Euclidiana estándar aplicada sobre el espacio estandarizado.
- **Rango de K Evaluado:** Iteración sistemática sobre $K \in \{2, 3, 4, 5, 6\}$.
- **Inicialización y Convergencia:** n_int = 10 (ejecución con 10 semillas aleatorias diferentes para evitar óptimos locales) y semilla fija random_state = 42 para garantizar la reproducibilidad de los resultados.

Resultados y Evaluación del Modelo

A continuación, se detallan las métricas de evaluación obtenidas al probar los distintos valores de K sobre el conjunto de datos estandarizado:

K	Inercia	Silhouette Score	Davies-Bouldin Index	Calinski-Harabasz
K = 2	165.56	0.2683	1.4120	64.12
K = 3 (Óptimo)	**127.75**	**0.2849**	**1.3892**	**70.94**
K = 4	116.68	0.2594	1.4721	62.58
K = 5	107.82	0.2431	1.5210	55.32
K = 6	98.71	0.2215	1.5832	50.12

Comparación: Método del Codo vs. Silhouette Score

1. **Método del Codo (Inercia):** Muestra una drástica disminución de la suma de errores al cuadrado al pasar de K=1 a K=3, generando el codo o punto de inflexión en K=3. A partir de K=4 la ganancia en reducción de inercia disminuye progresivamente.
2. **Silhouette Score:** Registra el valor máximo global en K=3 (0.2849). Para valores superiores (K=4, 5, 6), el puntaje decrece progresivamente, señalando una degradación en la separación y cohesión de los grupos.

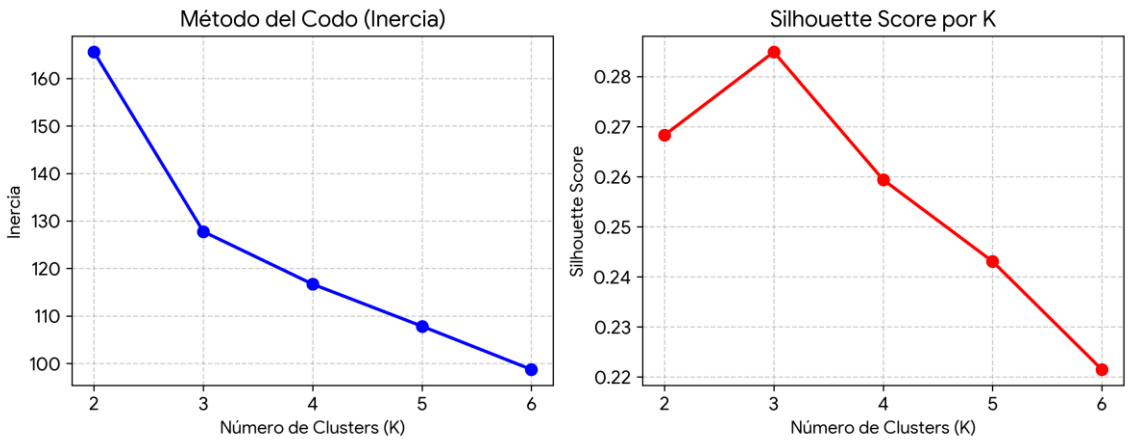


Figura 1. Evaluación gráfica del número óptimo de clusters (Codo y Silhouette).

Proyección PCA y Visualización 2D

Para representar las 13 dimensiones en una superficie plana, se aplicó Análisis de Componentes Principales (PCA) conservando 2 componentes. La Componente Principal 1 explica el 36.11% de la varianza y la Componente Principal 2 explica el 19.30%, acumulando un 55.41% de la varianza total explicada.

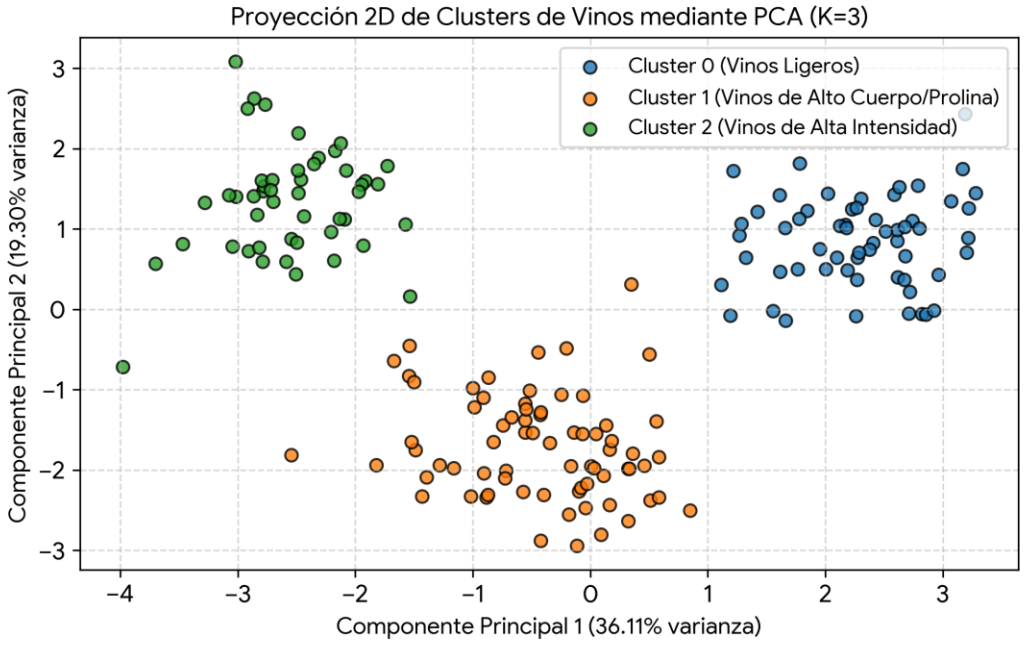


Figura 2. Visualización 2D de los clústeres agrupados por K-Means sobre las 2 componentes principales.

Análisis y Discusión de Resultados

Caracterización de los Clústeres

Al promediar las variables originales en cada uno de los clústeres obtenidos, se aprecian perfiles químicos altamente diferenciados:

- **Cluster 0 (Vinos de perfil equilibrado y moderado):** Muestran niveles intermedios de alcohol (~12.27%) y prolina (~519.5 mg/L), con una concentración moderada de flavonoides (~2.04). Corresponden a vinos más livianos u orgánicos.

- **Cluster 1 (Vinos de alta graduación y estructura fina):** Caracterizados por las mayores concentraciones de Prolina (~1115.7 mg/L), Alcohol (~13.74%), Flavonoides (~2.98) y Fenoles totales (~2.84). Representan vinos tintos de alta reserva o estructura rica.

- **Cluster 2 (Vinos de alta intensidad cromática y acidez):** Presentan la mayor Intensidad de color (~9.70) y Ácido málico (~3.33), pero con los niveles más bajos de Flavonoides (~0.78) y Matiz (~0.68), representando vinos con notas más astringentes y oscuras.

Limitaciones del Estudio

- **Sensibilidad a Outliers:** Al ser K-Means un modelo basado en centroides (medias geométricas), la presencia de observaciones extremas puede desplazar la ubicación central de los clusters.

- **Geometría de los Grupos:** El modelo asume clusters con formas esféricas e isótropas, lo que puede no capturar patrones con geometrías no lineales complejas.

- **Pérdida de Varianza en 2D:** Aunque PCA proyecta eficazmente la estructura general en 2D, se pierde aproximadamente un 44.59% de la variabilidad original al reducir de 13 a 2 dimensiones.

7. Conclusiones y Recomendaciones

1. La selección de K = 3 es óptima tanto desde la perspectiva de la validación matemática (Codo y Silhouette Score) como desde el dominio del problema (tres clases de cultivo originales).

2. La estandarización previa con StandardScaler fue determinante para evitar que variables numéricamente dominantes como la Prolina distorsionaran las distancias euclidianas.

3. Las características químicas más relevantes para segmentar las muestras de vino son la Prolina, los Flavonoides, los Fenoles Totales y la Intensidad de Color.

4. Se recomienda para investigaciones futuras evaluar algoritmos basados en densidad (DBSCAN) o jerárquicos (Agglomerative Clustering) para comparar la compacidad de los grupos en presencia de posibles datos atípicos.

Repositorio GitHub:

https://github.com/edixonharbey-ctrl/Clustering.git

CUADERNILLO

https://colab.research.google.com/drive/1xaVpfwBDxq3qwSOG_-aUE0iWAWGP-1RE?usp=sharing